

# Regressão Logística

10 de julho de 2023

## 1 Exercícios

1. Considere um único ponto de dados com um único recurso. Seu objetivo é prever se um email é spam (1) ou não (0) com base na frequência de uma palavra. Se a frequência da palavra for 0.3 e o email não for spam, qual é o valor da função log-verossimilhança se  $\beta = [0, 0]$ ? Use a fórmula para a função log-verossimilhança dada anteriormente.
2. Usando o mesmo ponto de dados do Exercício 1, qual é o gradiente da função log-verossimilhança se  $\beta = [0, 0]$ ? Use as fórmulas para as derivadas parciais dadas anteriormente.
3. Ainda referindo-se ao ponto de dados do Exercício 1, se você usar a subida do gradiente com uma taxa de aprendizado de 0.1 para atualizar  $\beta$ , qual será o novo valor de  $\beta$ ?
4. Agora considere um segundo ponto de dados com frequência de palavra 0.7 e o email é spam. Calcule o valor da função log-verossimilhança e seu gradiente para esses dois pontos de dados se  $\beta = [0, 0]$ .
5. Ainda usando os dois pontos de dados do Exercício 4, se você usar a subida do gradiente com uma taxa de aprendizado de 0.1 para atualizar  $\beta$ , qual será o novo valor de  $\beta$ ?
6. Considere agora três pontos de dados: (0.3, 0), (0.7, 1), (0.1, 0), onde o primeiro número de cada par é a frequência da palavra e o segundo número indica se o email é spam. Calcule o valor da função log-verossimilhança e seu gradiente para esses três pontos de dados se  $\beta = [0, 0]$ . Em seguida, use a subida do gradiente com uma taxa de aprendizado de 0.1 para atualizar  $\beta$ . Qual é o novo valor de  $\beta$ ?

## 2 Soluções

### 1. \*\*Exercício 1:\*\*

Para calcular a função log-verossimilhança, primeiro precisamos calcular a probabilidade prevista  $p = \frac{1}{1+e^{-(\beta_0+\beta_1 x)}} = \frac{1}{1+e^{-(0+0*0.3)}} = 0.5$ .

Então a log-verossimilhança é  $y \log(p) + (1-y) \log(1-p) = 0 \log(0.5) + (1-0) \log(1-0.5) = -\log(2)$ .

$$p = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}} = \frac{1}{1 + e^{-(0 + 0 \cdot 0.3)}} = 0.5$$
$$L(\beta) = y \log(p) + (1 - y) \log(1 - p) = 0 \log(0.5) + (1 - 0) \log(1 - 0.5) = -\log(2)$$

### 2. \*\*Exercício 2:\*\*

Para calcular o gradiente da função log-verossimilhança, precisamos calcular suas derivadas parciais em relação a  $\beta_0$  e  $\beta_1$ .

Usando as fórmulas fornecidas, temos  $\frac{\partial \log L(\beta)}{\partial \beta_0} = y - p = 0 - 0.5 = -0.5$  e  $\frac{\partial \log L(\beta)}{\partial \beta_1} = (y - p)x = (0 - 0.5)0.3 = -0.15$ . Portanto, o gradiente é  $[-0.5, -0.15]$ .

$$\begin{aligned}\frac{\partial \log L(\beta)}{\partial \beta_0} &= y - p = 0 - 0.5 = -0.5 \\ \frac{\partial \log L(\beta)}{\partial \beta_1} &= (y - p)x = (0 - 0.5)0.3 = -0.15\end{aligned}$$

3. **\*\*Exercício 3:\*\***

Para atualizar  $\beta$ , subtraímos a taxa de aprendizado vezes o gradiente de  $\beta$ . Portanto,  $\beta \leftarrow \beta - \eta \nabla \log L(\beta) = [0, 0] - 0.1 * [-0.5, -0.15] = [0.05, 0.015]$ .

$$\beta \leftarrow \beta - \eta \nabla \log L(\beta) = [0, 0] - 0.1 \cdot [-0.5, -0.15] = [0.05, 0.015]$$

4. **\*\*Exercício 4:\*\***

Para dois pontos de dados, calculamos a probabilidade prevista e a log-verossimilhança para cada ponto e somamos os resultados.

Para o primeiro ponto de dados (0.3, 0), temos  $p = 0.5$  e a log-verossimilhança é  $-\log(2)$ , como calculamos no Exercício 1.

Para o segundo ponto de dados (0.7, 1), também temos  $p = 0.5$  e a log-verossimilhança é  $\log(0.5) = -\log(2)$ .

Portanto, a log-verossimilhança para os dois pontos de dados é  $-\log(2) - \log(2) = -2\log(2)$ .

O gradiente também é a soma dos gradientes para cada ponto de dados. Portanto, o gradiente para  $\beta_0$  é  $-0.5 - 0.5 = -1$  e o gradiente para  $\beta_1$  é  $-0.15 - 0.35 = -0.5$ . O gradiente total é  $[-1, -0.5]$ .

$$\begin{aligned}L(\beta) &= -\log(2) - \log(2) = -2\log(2) \\ \frac{\partial \log L(\beta)}{\partial \beta_0} &= -0.5 - 0.5 = -1 \\ \frac{\partial \log L(\beta)}{\partial \beta_1} &= -0.15 - 0.35 = -0.5\end{aligned}$$

5. **\*\*Exercício 5:\*\***

Para atualizar  $\beta$ , subtraímos a taxa de aprendizado vezes o gradiente de  $\beta$ . Portanto,  $\beta \leftarrow \beta - \eta \nabla \log L(\beta) = [0, 0] - 0.1 * [-1, -0.5] = [0.1, 0.05]$ .

$$\beta \leftarrow \beta - \eta \nabla \log L(\beta) = [0, 0] - 0.1 \cdot [-1, -0.5] = [0.1, 0.05]$$

6. **\*\*Exercício 6:\*\***

Para três pontos de dados, procedemos da mesma forma que no Exercício 4, somando as log-verossimilhanças e gradientes para cada ponto de dados.

A log-verossimilhança para os três pontos de dados é  $-\log(2) - \log(2) - \log(2) = -3\log(2)$ .

O gradiente para  $\beta_0$  é  $-0.5 - 0.5 - 0.5 = -1.5$  e o gradiente para  $\beta_1$  é  $-0.15 - 0.35 - 0.05 = -0.55$ . O gradiente total é  $[-1.5, -0.55]$ .

Para atualizar  $\beta$ , temos  $\beta \leftarrow \beta - \eta \nabla \log L(\beta) = [0, 0] - 0.1 * [-1.5, -0.55] = [0.15, 0.055]$ .

$$L(\beta) = -\log(2) - \log(2) - \log(2) = -3 \log(2)$$

$$\frac{\partial \log L(\beta)}{\partial \beta_0} = -0.5 - 0.5 - 0.5 = -1.5$$

$$\frac{\partial \log L(\beta)}{\partial \beta_1} = -0.15 - 0.35 - 0.05 = -0.55$$

$$\beta \leftarrow \beta - \eta \nabla \log L(\beta) = [0, 0] - 0.1 \cdot [-1.5, -0.55] = [0.15, 0.055]$$